[과제] Bloom Filter & Flajolet-Martin

소프트웨어학부

20203066 박민희

Bloom Filter

```
import math
import mmh3
import random


class BloomFilter:
    def __init__(self,capacity,fp_prob): #capacity = m,fp_brob = false
positive 비율
        self.capacity = capacity #언제쓸지 모르니까 인스턴스에 멤버변수로 넣어주기
        self.fp_prob = fp_prob
        self.bitarray = 0
        self.n_bits = math.ceil(-
math.log(fp_prob,math.e)*capacity/(math.log(2,math.e)**2)) #bitarray
크기인듯?
        self.n_hashs = int(self.n_bits / capacity* math.log(2,math.e)) #hash
개수
        #print(self.n_bits)
        #print(self.n_hashs)
        self.seeds = [random.randint(0,999999) for i in range(self.n_hashs)]

    def put(self,item):
        for i in range(self.n_hashs): #hash 개수 만큼 해시를 돌림
            pos = mmh3.hash(item,self.seeds[i]) % self.n_bits
            self.bitarray |= (1<<pos) #bitarray 에다가 set , 1 에서 pos 만큼
shift 시켜서 #그럼 해당위치에 set 됩니당.

    def test(self,item): #item 이 들어왔을때 그 item 을 hash 를 해서 pos 를 구하고
해당 pos 가 전부 다 1 이면 있을수도 있다~
        for i in range(self.n_hashs):
            pos = mmh3.hash(item,self.seeds[i]) % self.n_bits

            if self.bitarray & (1<<pos) == 0: #이게 true 면 0, false 면 1
                return False
        return True

bloom = BloomFilter(10, 0.1)

bloom.put('a')
bloom.put('b')
bloom.put('c')
bloom.put('d')
bloom.put('e')
```

```
print('a',bloom.test('a'))
print('b',bloom.test('b'))
print('c',bloom.test('c'))
print('d',bloom.test('d'))
print('e',bloom.test('e'))
print('f',bloom.test('f'))
print('g',bloom.test('g'))
print('h',bloom.test('h'))
print('i',bloom.test('i'))
print('j',bloom.test('j'))
print('k',bloom.test('k'))
print('l',bloom.test('l'))
print('m',bloom.test('m'))
print('n',bloom.test('n'))
```

위 코드의 결과는

a True

b True

c True

d True

e True

f False

g False

h False

i False

j False

k False

l True

m False

n False

로 출력되었다.

1억명의 사용자 계정이 시스템에 저장되어 있고, 사용자가 회원가입 중에 동일한 계정명이 서버에 존재하는지 즉각확인하는 시스템을 개발할 때 Bloom Filter를 활용한다면 동일한 계정명이 서버에 존재하는지를 잘 확인할수 있을것이다. 동일한 계정명이 서버에 없는데 있다고 나올순 있지만 없는데 있다고 나올수는 없기 때문이다.

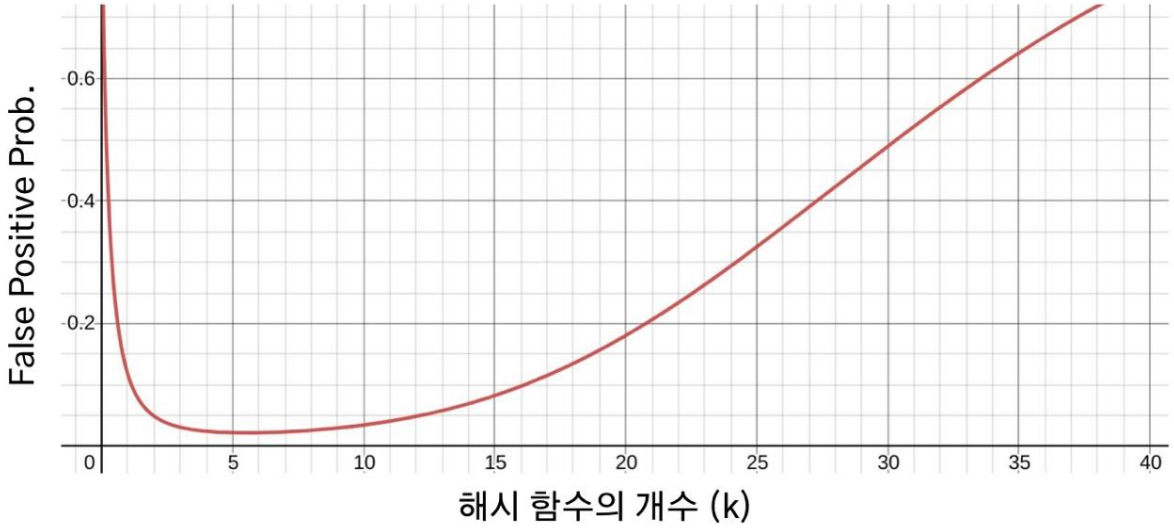

위의 그래프에서 볼수 있듯 False Positive 확률은 해시함수에 따라 다른데 최 저점일때의 해시함수는 n/m ln(2)이다 이때 n은 비트배열의 크기,m은 집합 s의 크기이다.

이로 볼 때 알수 있는 것은 비트배열의 크기가 너무 커져서는 안된다는 것이다. k의 값이 적절할 때 False Positive의 값이 최저이다. 그래프에서 k의 값이 5때를 최저라고 생각했을 때 적절한 비트배열의 크기는 n/1억*ln(2)=5를 풀었을 때 나오는 n의 값이 적절할수 있을거라고 생각한다.

또한 학교 컴퓨터를 사용한사람 중 최근 일주일동안 ecampus에 로그인한 사람만의 이력을 뽑는다고 하였을 때 국민대학교 ecampus사용자 데이터를 이용하여 bloom filter를 만들고 국민대 ecampus사용자가 아닌 사람을 첫번째로 확실하게 거를수 있을으므로 bloom filter가 도음이 될수 있을것같다.

Flajolet-Martin

ver1.

```
import mmh3
import math
import random
import  matplotlib.pyplot as plt
from tqdm import tqdm

class FM:
    def __init__(self,domain_size):
        self.bitarray = 0
        self.domain_size = domain_size
        self.n_bits = math.ceil(math.log2(domain_size)) #몇개의 bit 를 쓸건지?
        self.mask = (1 << self.n_bits) -1 #11111111
        self.seed = random.randint(0,999999)

    def put(self,item): #item 들어오면 hash 하고 위치찾고 bitarray 에서 해당위치
```

```
1 인애 설정하면 됑
        h = mmh3.hash(item,self.seed) & self.mask #hash 하는 부분??
        r = 0
        if h == 0 : return
        while (h & (1 << r)) == 0 : r += 1 #1 위치 찾기
        self.bitarray |= (1 << r) #bitarray 에 r 번 위치에다가 1 을 셋팅하는ㄴ겨


    def size(self): #2**R
        R = self.n_bits-1
        while self.bitarray & (1 << R) == 0: R -= 1  # bitarray 에서 쩰 큰 1 이
나오는 곳 찾는거 ,,
        #print(self.bitarray)
        return 2 ** R

fm = FM(1000000)
tset = set() #True set

x = []
y = []


for i in tqdm(range(10000)):
    item = str(random.randint(0, 100000))
    fm.put(item)
    tset.add(item)

    x.append(len(tset))
    y.append(fm.size())

plt.scatter(x,y)
plt.plot(x,x,color='r')
plt.show()
    #print(f"true: {len(tset)}, estimated: {fm.size()}")
```

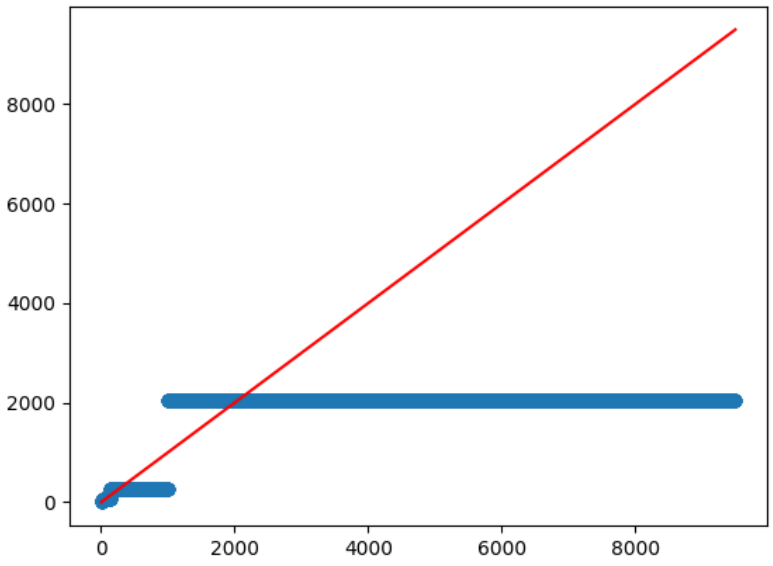

ver2.

```
import mmh3
import math
import random
import  matplotlib.pyplot as plt
from tqdm import tqdm

class FM:
    def __init__(self,domain_size,n_groups):
        self.domain_size = domain_size
        self.n_groups = n_groups
        self.n_bits = math.ceil(math.log2(domain_size)) #몇개의 bit를 쓸건지?
        self.mask = (1 << self.n_bits) -1 #11111111
        self.seed = 100 #해시함수 개수입미당
        self.seeds = [random.randint(0,999999) for i in range(self.seed)]
        self.bitarray = [0 for i in range(self.seed)]

    def put(self,item): #item들어오면 hash하고 위치찾고 bitarray에서 해당위치 1인애 설정하면 됭
        for i in range(self.seed):
            h = (mmh3.hash(item,self.seeds[i]) & self.mask) #hash하는 부분??
            r = 0
            if h == 0 : return
            while (h & (1 << r)) == 0 : r += 1
            self.bitarray[i] |= (1 << r) #bitarray에 r번 위치에다가 1을 셋팅하는ㄴ겨


    def size(self): #2**R/Φ
        group = [[] for i in range(self.n_groups)]
        R = 0
        for i in range(self.seed):
            while self.bitarray[i] & (1 << R) != 0: R += 1 #bitarray에서 처음 0이 나오는 곳 찾는거 ,, 그
            group[i%self.n_groups].append(2 ** R / 0.77351)
        jungahng = 0
        for i in group:
            i.sort()
            jungahng += i[len(i)//2]

        return jungahng/self.n_groups

fm = FM(100000,10)
tset = set() #True set

x = []
y = []


for i in tqdm(range(100000)):
    item = str(random.randint(0, 100000))
    fm.put(item)
```

```
    tset.add(item)


    x.append(len(tset))
    y.append(fm.size())

plt.scatter(x,y)
plt.plot(x,x,color='r')
plt.show()
    #print(f"true: {len(tset)}, estimated: {fm.size()}")
```

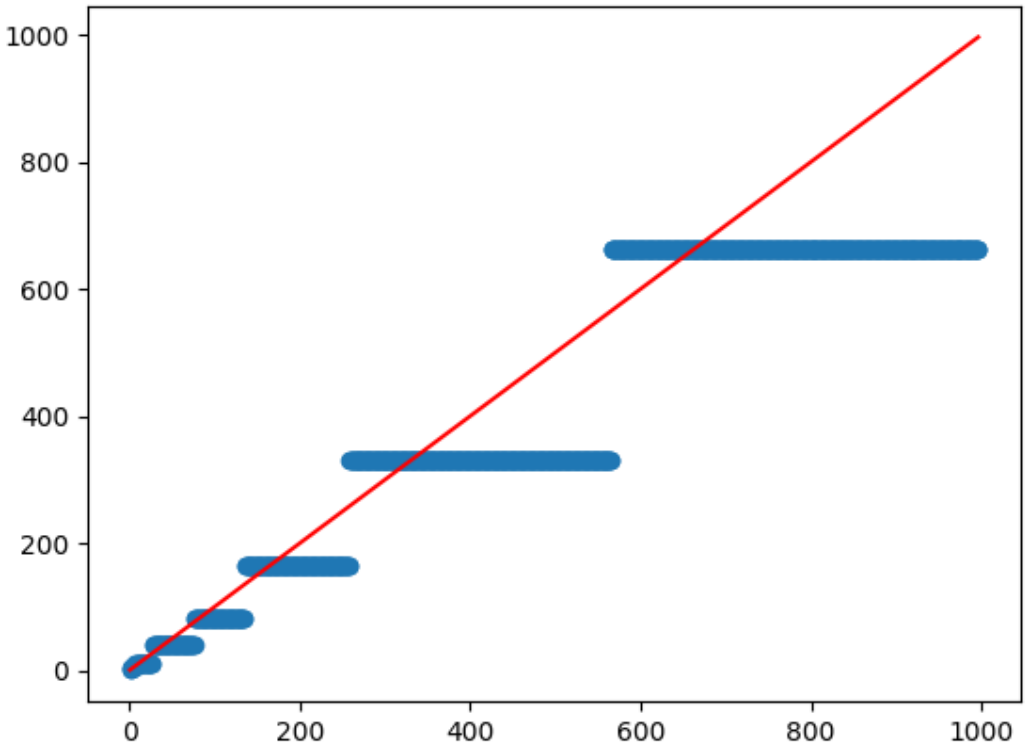

ver1에 비해서 ver2가 확실히 정확도가 높아진 것을 볼 수 있다.

해시 함수의 수를 일정하게 두고 보았을 때 그룹의 수가 많은 것보다 적을 때 더 결과가 조금더 정확히 추측된것 같다. 또한 그룹의 수를 일정하게 두고 해시함수의 수를 변화시켜보았을 때 해시함수가 과하게 많은 것은 의미가 없는 것 같다고 생각되었다. 해시함수가 일정 수를 지나고 난 후에는 결과가 크게 다르지 않다고 느꼈다.